

SAE – Statistiques et Inférence

Rapport d'analyse statistique

BUT Science des Données



Table des matières

Introduction générale.....	3
Partie 1 – Sondage sur la population des communes de PACA	4
1.1 Introduction et contexte	4
1.2 Sondage aléatoire simple (SAS).....	4
1.3 Sondage stratifié.....	5
1.4 Conclusion – Partie 1.....	8
Partie 2 – Enquête Sport Étudiant 2024	9
2.1 Introduction et contexte	9
2.2 Préparation des données.....	9
2.3 Tableaux croisés.....	10
2.4 Tests khi-deux et V de Cramer	10
2.5 Conclusion – Partie 2.....	12
Conclusion générale.....	13

Introduction générale

Dans le cadre de la SAE (Situation d'Apprentissage et d'Évaluation) de statistiques et inférence de première année de BUT Science des Données, ce rapport présente les résultats de deux études statistiques menées sur des données réelles.

La première étude porte sur l'estimation de la population totale des communes de la région Provence-Alpes-Côte d'Azur (PACA) à partir de méthodes de sondage simples et stratifiées. La seconde analyse les liens entre la pratique sportive des étudiants et différentes variables sociodémographiques collectées lors d'une enquête menée en 2024.

Ces deux parties mobilisent des outils statistiques complémentaires : d'un côté l'estimation par intervalles de confiance dans un cadre de sondage probabiliste, de l'autre les tests d'indépendance du khi-deux associés au V de Cramer pour mesurer l'intensité des liaisons entre variables qualitatives. L'ensemble des traitements a été réalisé sous le logiciel R.



Partie 1 – Sondage sur la population des communes de PACA

1.1 Introduction et contexte

L'objectif de cette première partie est d'estimer le nombre total d'habitants de la région PACA à partir d'un échantillon de communes, sans avoir à recenser l'ensemble des 961 communes que compte la région. Deux méthodes de sondage sont comparées : le sondage aléatoire simple (SAS) et le sondage stratifié.

Les données proviennent du fichier Excel `population_francaise_communes.xlsx`. Après filtrage sur la région PACA, chaque commune est décrite par son département, son nom et sa population totale.

```
Import des librairies et des données puis visualisation du fichier
library(readxl) # pour lire les fichiers Excel
library(sampling) # pour les méthodes de sondage (strata, getdata)

donnees <- read_excel("population_francaise_communes.xlsx", sheet = "Communes")

str(donnees)
head(donnees)
```

Préparation et nettoyage des données

```
donnees <- subset(donnees,
                  `Nom de la région` == "Provence-Alpes-Côte d'Azur",
                  select = c("Code département", "Commune", "Population totale"))

colnames(donnees) <- c("codeDep", "com", "popTot")

U <- donnees$com # liste des communes
N <- length(U)   # nombre total de communes
T <- sum(donnees$popTot) # total habitants PACA (valeur de référence)
```

1.2 Sondage aléatoire simple (SAS)

Le sondage aléatoire simple consiste à tirer un échantillon $n = 50$ communes au hasard parmi les N communes de PACA, sans remise. L'estimateur du total de la population est $\hat{T} = N \times \bar{x}$, où $\bar{x}$ est la moyenne des populations des communes tirées. Un intervalle de confiance à 95 % est construit via le test de Student (ici utilisé car $n = 50$ est petit et que la variance n'est pas connue).

Cette procédure est répétée 10 fois afin d'observer la variabilité des estimations d'un tirage à l'autre.

Voir le code ci-dessous :

```

# -----
# PARTIE A : SONDAGE ALÉATOIRE SIMPLE - 10 répétitions
# -----

resultat = data.frame(Pop_exacte = numeric(), Pop_estim = numeric(), Marge = numeric())

for (i in 1:10) {

  n = 50
  E = sample(U, n)
  donnees1 = donnees[donnees$com %in% E, ]

  xbar = mean(donnees1$popTot)
  idcmoy = t.test(donnees1$popTot)$conf.int

  T_est = N * xbar
  idcT = idcmoy * N
  marge = (idcT[2] - idcT[1]) / 2

  new_row = data.frame(Pop_exacte = T_reel, Pop_estim = T_est, Marge = marge)
  resultat = rbind(resultat, new_row)
}


resultat
write.csv2(resultat, "resultat.csv")

```

Le tableau ci-contre correspond aux observations de notre sondage aléatoire simple.

	Pop_exacte	Pop_estim	Marge
1	5174034	6028064,7	4102316,5
2	5174034	5027336,96	2942117,84
3	5174034	4569366,57	3372108,73
4	5174034	5525260,08	3015873,36
5	5174034	5074368,3	2307450,96
6	5174034	4161824,06	2104029,17
7	5174034	3998647,08	2061853,66
8	5174034	5917555,35	3971161,28
9	5174034	3867648,14	2152834,71
10	5174034	5405375,14	4362166,03

Ces résultats se traduisent par le graphique ci-dessous. Il nous montre que nos estimations sont loin d'être parfaites avec la plupart s'éloignant de la population réelle.



1.3 Sondage stratifié

Pour améliorer la précision de l'estimation, les communes sont réparties en 6 strates homogènes selon leur taille (< 500 hab., 500–1 000, 1 000–2 000, 2 000–4 500, 4 500–20 000, > 20 000 hab.). Dans chaque strate, le nombre de communes à tirer est déterminé par allocation proportionnelle à la taille de la strate.

L'estimateur de la moyenne stratifiée est $\bar{x}_{st} = \sum (N_h/N) \times m_h$, et la variance de cet estimateur est calculée strate par strate avant d'en déduire l'intervalle de confiance global. Cette procédure est également répétée 10 fois.

Préparation des 6 strates afin d'étudier la population

```
summary(donnees$popTot)

# Découpage en 6 strates selon la taille de la commune
donnees$strate <- cut(donnees$popTot,
                      breaks = c(0, 500, 1000, 2000, 4500, 20000, Inf),
                      labels = c(1, 2, 3, 4, 5, 6))

donneesstrat <- donnees[, c("com", "popTot", "strate")]

resultat2 <- data.frame(Pop_exacte = numeric(),
                        Pop_estim  = numeric(),
                        Marge       = numeric())
```

Calcul des estimations selon nos strates

```

for (i in 1:10) {

  data = donneesstrat[order(donneesstrat$strate), ]

  Nh = table(data$strate)
  N = sum(Nh)
  gh = Nh / N

  n = 50
  nh = round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N, n*Nh[5]/N, n*Nh[6]/N))
  fh = nh / Nh

  # tirage stratifié SANS remise
  st = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
  data1 = getdata(data, st)

  ech1 = data1[data1$strate == 1, ]
  ech2 = data1[data1$strate == 2, ]
  ech3 = data1[data1$strate == 3, ]
  ech4 = data1[data1$strate == 4, ]
  ech5 = data1[data1$strate == 5, ]
  ech6 = data1[data1$strate == 6, ]

  m1 = mean(ech1$popTot) ; var1 = var(ech1$popTot)
  m2 = mean(ech2$popTot) ; var2 = var(ech2$popTot)
  m3 = mean(ech3$popTot) ; var3 = var(ech3$popTot)
  m4 = mean(ech4$popTot) ; var4 = var(ech4$popTot)
  m5 = mean(ech5$popTot) ; var5 = var(ech5$popTot)
  m6 = mean(ech6$popTot) ; var6 = var(ech6$popTot)

  Xbarst = (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4 + Nh[5]*m5 + Nh[6]*m6) / N

  # variance de l'estimateur (facteur de correction fini : 1 - fh)
  varXbarst = gh[1]^2*(1-fh[1])*var1/nh[1] + gh[2]^2*(1-fh[2])*var2/nh[2] +
    gh[3]^2*(1-fh[3])*var3/nh[3] + gh[4]^2*(1-fh[4])*var4/nh[4] +
    gh[5]^2*(1-fh[5])*var5/nh[5] + gh[6]^2*(1-fh[6])*var6/nh[6]


  alpha = 0.05
  binf = Xbarst - qnorm(1-alpha/2) * sqrt(varXbarst)
  bsup = Xbarst + qnorm(1-alpha/2) * sqrt(varXbarst)

  Tstr = N * Xbarst
  marge = (bsup - binf) * N / 2

  new_row = data.frame(Pop_exacte = T_reel, Pop_estim = Tstr, Marge = marge)
  resultat2 = rbind(resultat2, new_row)
}

```

Visualisation de nos résultats après strates





1.4 Conclusion – Partie 1

La comparaison des deux méthodes montre que le sondage stratifié produit des marges d'erreur systématiquement plus faibles que le sondage aléatoire simple, à taille d'échantillon totale comparable. Sur 10 répétitions avec une population réelle de 5 174 034 habitants, la marge d'erreur moyenne du SAS est de 3 191 660 contre 1 296 906 pour le sondage stratifié, soit une réduction de 59 %. L'estimation moyenne du SAS (4 515 659) s'écarte de -12,7 % du total réel, contre -0,8 % pour le stratifié (5 134 093). En divisant la population en strates homogènes, on réduit la variance interne de chaque groupe et donc l'incertitude globale sur l'estimation.

Ce résultat illustre l'intérêt pratique de la stratification lorsqu'on dispose d'une variable auxiliaire (ici la taille de la commune) fortement corrélée à la variable d'intérêt.

On voit bien ici dans les 2 graphiques ci-dessous qu'en utilisant les strates, on obtient des résultats plus précis qu'en simple.



Partie 2 – Enquête Sport Étudiant 2024

2.1 Introduction et contexte

Cette seconde partie analyse les données de l'enquête Sport Étudiant 2024, collectée auprès des étudiants en BUT à l'Université de Poitiers. L'objectif est d'identifier quelles variables sociodémographiques ou comportementales sont significativement liées à la pratique sportive déclarée.

Le fichier EnqueteSportEtudiant2024.csv comporte 375 répondants et 76 variables. Après nettoyage (suppression des lignes avec des valeurs manquantes sur sexe, sport, niveau, alternant, département de formation et réussite), l'analyse porte sur 361 individus (272 pratiquants du sport, soit 75,3 %).

Import des données et visualisation du fichier

```
donnees_brut = read.csv2("EnqueteSportEtudiant2024.csv", encoding="UTF-8", quote="")
str(donnees_brut)
head(donnees_brut)
```

2.2 Préparation des données

Les variables retenues pour l'analyse sont : le fait d'être fan de sport, le département de formation (GEA, HSE, SD), la réussite perçue, les habitudes alimentaires, le sexe, le statut d'alternant et le niveau d'études (BUT1 à Licence Pro). La variable cible est sport (Oui / Non).

```
# Conserver uniquement les répondants valides
# Note : bourse exclue du filtre global (trop de valeurs manquantes -> perte de ~133 individus)
d = subset(d,
  sexe %in% c("Un homme", "Une femme") &
  sport %in% c("Oui", "Non") &
  niveau != "" &
  alternant %in% c("Non", "Oui") &
  deptformation %in% c("GEA", "HSE", "SD") &
  reussite != "")

# Mise en facteur
d$sport = factor(d$sport, levels = c("Non", "Oui"))
d$fan = factor(d$fan, levels = c("Non", "Oui"))
d$deptformation = factor(d$deptformation)
d$sexe = factor(d$sexe, levels = c("Un homme", "Une femme"))
d$niveau = factor(d$niveau, levels = c("BUT1", "BUT2", "BUT3", "Licence Pro"))
d$alimentation = factor(d$alimentation, levels = c("Non", "Oui"))
d$alternant = factor(d$alternant, levels = c("Non", "Oui"))
d$reussite = factor(d$reussite)

head(d[, c("fan", "deptformation", "sexe", "niveau",
  "alimentation", "alternant", "reussite", "sport")])
```

2.3 Tableaux croisés

Pour chacune des 7 variables candidates, un tableau croisé avec la variable sport a été construit. Seules les variables dont le test du khi-deux est significatif au seuil 5 % sont conservées pour la suite de l'analyse.

Tableau croisé entre fan et sport

Fan		
Sport	Non	Oui
Non	70	19
Oui	76	196

Tableau croisé entre département de formation et sport

Dept			
Sport	GEA	HSE	SD
Non	47	15	27
Oui	87	96	89

Tableau croisé entre alimentation et sport

Alimentation		
Sport	Non	Oui
Non	45	44
Oui	77	195

Tableau croisé entre niveau d'étude et sport

Niveau					
Sport	BUT1	BUT2	BUT3	Licence	Pro
Non	45	26	15		3
Oui	102	79	63		28

Tableau croisé entre sexe et sport

Sexe		
Sport	Un homme	Une femme
Non	48	41
Oui	199	73

Tableau croisé entre alternance et sport

Alternant		
Sport	Non	Oui
Non	67	22
Oui	168	104

Tableau croisé entre réussite et sport

Reussite				
Sport	Moyennement d'accord	Oui	Pas vraiment d'accord	Tout à fait d'accord
Non		39	1	9
Oui		72	0	19

2.4 Tests khi-deux et V de Cramer

Le test du khi-deux vérifie l'hypothèse nulle d'indépendance entre sport et chaque variable.

```
# -----
# TESTS KHI-DEUX
# -----

khideux_fan          = chisq.test(TCD_fan,                correct = FALSE)
khideux_deptformation = chisq.test(TCD_deptformation,    correct = FALSE)
khideux_reussite      = chisq.test(TCD_reussite,          correct = FALSE)
khideux_alimentation  = chisq.test(TCD_alimentation,      correct = FALSE)
khideux_sexe          = chisq.test(TCD_sexe,              correct = FALSE)
khideux_alternant     = chisq.test(TCD_alternant,         correct = FALSE)
khideux_niveau        = chisq.test(TCD_niveau,           correct = FALSE)
```

Le V de Cramer mesure ensuite l'intensité de la liaison (de 0 = aucune liaison à 1 = liaison parfaite).

```
# -----
# V DE CRAMER
# -----

n = nrow(d)

p = nrow(TCD_fan)          ; q = ncol(TCD_fan)          ; m = min(p-1, q-1)
V_fan = sqrt(khideux_fan$statistic / (n*m))
V_fan

p = nrow(TCD_deptformation); q = ncol(TCD_deptformation); m = min(p-1, q-1)
V_deptformation = sqrt(khideux_deptformation$statistic / (n*m))
V_deptformation

p = nrow(TCD_reussite)     ; q = ncol(TCD_reussite)     ; m = min(p-1, q-1)
V_reussite = sqrt(khideux_reussite$statistic / (n*m))
V_reussite

p = nrow(TCD_alimentation) ; q = ncol(TCD_alimentation) ; m = min(p-1, q-1)
V_alimentation = sqrt(khideux_alimentation$statistic / (n*m))
V_alimentation

p = nrow(TCD_sexe)         ; q = ncol(TCD_sexe)         ; m = min(p-1, q-1)
V_sexe = sqrt(khideux_sexe$statistic / (n*m))
V_sexe

p = nrow(TCD_alternant)    ; q = ncol(TCD_alternant)    ; m = min(p-1, q-1)
V_alternant = sqrt(khideux_alternant$statistic / (n*m))
V_alternant

p = nrow(TCD_niveau)       ; q = ncol(TCD_niveau)       ; m = min(p-1, q-1)
V_niveau = sqrt(khideux_niveau$statistic / (n*m))
V_niveau
```

Parmi les 7 variables testées, 6 sont significativement liées à la pratique sportive ($p < 0,05$) :

- Sexe ($p = 0,001$, V de Cramer = 0,1783) : les hommes pratiquent davantage le sport que les femmes.
- Alimentation ($p < 0,001$, V de Cramer = 0,2028) : les étudiants déclarant une bonne alimentation sont proportionnellement plus sportifs.
- Alternant ($p = 0,020$, V de Cramer = 0,1222) : les alternants pratiquent davantage le sport que les non-alternants.
- Niveau ($p = 0,051$) : résultat à la limite du seuil de significativité — tendance non confirmée au seuil 5 %.
- Fan ($p < 0,001$, V de Cramer = 0,4453) : les étudiants fans de sport pratiquent massivement le sport — variable la plus discriminante (196/272 pratiquants vs 19/89 non-pratiquants).
- Département de formation ($p < 0,001$, V de Cramer = 0,2063) : la filière GEA est nettement moins sportive (87/134) que HSE (96/111) et SD (89/116).
- Réussite ($p = 0,001$, V de Cramer = 0,2077) : les étudiants se considérant « tout à fait d'accord » avec leur réussite sont plus sportifs (181/221).

Seule la variable niveau ne franchit pas le seuil de 5 % ($p = 0,051$) et est donc écartée de l'analyse.

2.5 Conclusion – Partie 2

L'analyse met en évidence 6 variables significativement associées à la pratique sportive : fan ($V = 0,45$), réussite ($V = 0,21$), département de formation ($V = 0,21$), alimentation ($V = 0,20$), sexe ($V = 0,18$) et alternant ($V = 0,12$).

Variable	p_valeur	V_Cramer
fan	0.00000	0.4453
reussite	0.00138	0.2077
deptformation	0.00046	0.2063
alimentation	0.00012	0.2028
sexe	0.00071	0.1783
niveau	0.05060	0.1469
alternant	0.02023	0.1222

La variable fan présente une association de force modérée ; les autres variables restent dans la catégorie « faible ». Aucune variable prise isolément ne prédit fortement la pratique sportive.

Ce résultat suggère que la pratique du sport est un comportement multifactoriel. Avec $n = 361$ individus, 6 variables atteignent le seuil de significativité : fan, département de formation, réussite, alimentation, sexe et alternant. Une approche multivariée (régression logistique, par exemple) permettrait d'affiner ces conclusions.

Conclusion générale

Ce rapport a présenté deux analyses statistiques complémentaires menées sous R dans le cadre de la SAE d'inférence statistique.

La première partie a démontré l'apport du sondage stratifié par rapport au sondage aléatoire simple pour l'estimation de la population totale d'une région : en regroupant les communes par strates homogènes, la précision de l'estimation est nettement améliorée à taille d'échantillon identique.

La seconde partie a mis en évidence des liaisons significatives entre la pratique sportive des étudiants et certaines de leurs caractéristiques (fan, sexe, alimentation, statut d'alternant, réussite et département de formation), tout en soulignant la faible intensité de ces liaisons prises individuellement.

Ces travaux constituent une première application concrète des méthodes statistiques étudiées en BUT SD et posent les bases pour des analyses plus avancées en deuxième année.

Annexe – code R

```
# =====
# PARTIE 1 - Sondage sur la population des communes de PACA
# =====

setwd("C:/Users/arthu/OneDrive - Université de Poitiers (1)/SAE/s2/statsInf")
library(readxl)
library(sampling)
donnees = read_excel("population_francaise_communes.xlsx", sheet = "Communes")

str(donnees)
head(donnees)

# On ne garde que les communes de PACA
donnees = subset(donnees,
                  `Nom de la région` == "Provence-Alpes-Côte d'Azur",
                  select = c("Code département", "Commune", "Population totale"))
colnames(donnees) = c("codeDep", "com", "popTot")

U = donnees$com
N = length(U)
T_reel = sum(donnees$popTot) # total habitants PACA (valeur de référence)
# -----
# PARTIE A : SONDAGE ALÉATOIRE SIMPLE - 10 répétitions
# -----

resultat = data.frame(Pop_exacte = numeric(), Pop_estim = numeric(), Marge = numeric())

for (i in 1:10) {
  n = 50
  E = sample(U, n)
  donnees1 = donnees[donnees$com %in% E, ]

  xbar = mean(donnees1$popTot)
  idcmoy = t.test(donnees1$popTot)$conf.int

  T_est = N * xbar
  idcT = idcmoy * N
  marge = (idcT[2] - idcT[1]) / 2

  new_row = data.frame(Pop_exacte = T_reel, Pop_estim = T_est, Marge = marge)
  resultat = rbind(resultat, new_row)
}
```

```
resultat
write.csv2(resultat, "resultat.csv")
# -----
# PARTIE B : SONDAGE STRATIFIÉ - 10 répétitions
# -----
summary(donnees$popTot)
# Découpage en 6 strates selon la taille de la commune
donnees$strate = cut(donnees$popTot,
                     breaks = c(0, 500, 1000, 2000, 4500, 20000, Inf),
                     labels = c(1, 2, 3, 4, 5, 6))
donneesstrat = donnees[, c("com", "popTot", "strate")]

resultat2 = data.frame(Pop_exacte = numeric(), Pop_estim = numeric(), Marge = numeric())

for (i in 1:10) {
  data = donneesstrat[order(donneesstrat$strate), ]

  Nh = table(data$strate)
  N = sum(Nh)
  gh = Nh / N

  n = 50
  nh = round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N, n*Nh[5]/N, n*Nh[6]/N))
  fh = nh / Nh
  # tirage stratifié SANS remise
  st = strata(data, stratanames = c("strate"), size = nh, method = "srswor")
  data1 = getdata(data, st)

  ech1 = data1[data1$strate == 1, ]
  ech2 = data1[data1$strate == 2, ]
  ech3 = data1[data1$strate == 3, ]
  ech4 = data1[data1$strate == 4, ]
  ech5 = data1[data1$strate == 5, ]
  ech6 = data1[data1$strate == 6, ]

  m1 = mean(ech1$popTot) ; var1 = var(ech1$popTot)
  m2 = mean(ech2$popTot) ; var2 = var(ech2$popTot)
  m3 = mean(ech3$popTot) ; var3 = var(ech3$popTot)
  m4 = mean(ech4$popTot) ; var4 = var(ech4$popTot)
  m5 = mean(ech5$popTot) ; var5 = var(ech5$popTot)
  m6 = mean(ech6$popTot) ; var6 = var(ech6$popTot)
```

```

Xbarst = (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4 + Nh[5]*m5 + Nh[6]*m6) / N
# variance de l'estimateur (facteur de correction fini : 1 - fh)
varXbarst = gh[1]^2*(1-fh[1])*var1/nh[1] + gh[2]^2*(1-fh[2])*var2/nh[2] +
            gh[3]^2*(1-fh[3])*var3/nh[3] + gh[4]^2*(1-fh[4])*var4/nh[4] +
            gh[5]^2*(1-fh[5])*var5/nh[5] + gh[6]^2*(1-fh[6])*var6/nh[6]

alpha = 0.05
binf = Xbarst - qnorm(1-alpha/2) * sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2) * sqrt(varXbarst)

Tstr = N * Xbarst
marge = (bsup - binf) * N / 2

new_row = data.frame(Pop_exacte = T_reel, Pop_estim = Tstr, Marge = marge)
resultat2 = rbind(resultat2, new_row)
}

resultat2
write.csv2(resultat2, "resultat2.csv")

# =====
# PARTIE 2 - Enquête Sport Étudiant 2024
# Relation entre sport et des variables qualitatives
# =====

d = read.csv2("EnqueteSportEtudiant2024.csv", fileEncoding = "UTF-8-BOM", quote = "")
# Conserver uniquement les répondants valides
# Note : bourse exclue du filtre global (trop de valeurs manquantes -> perte de ~133 individus)
d = subset(d,
           sexe %in% c("Un homme", "Une femme") &
           sport %in% c("Oui", "Non") &
           niveau != "" &
           alternant %in% c("Non", "Oui") &
           deptformation %in% c("GEA", "HSE", "SD") &
           reussite != "")

# Mise en facteur
d$sport = factor(d$sport, levels = c("Non", "Oui"))
d$fan = factor(d$fan, levels = c("Non", "Oui"))
d$deptformation = factor(d$deptformation)
d$sexe = factor(d$sexe, levels = c("Un homme", "Une femme"))
d$niveau = factor(d$niveau, levels = c("BUT1", "BUT2", "BUT3", "Licence Pro"))
d$alimentation = factor(d$alimentation, levels = c("Non", "Oui"))
d$alternant = factor(d$alternant, levels = c("Non", "Oui"))
d$reussite = factor(d$reussite)

```

```

head(d[, c("fan", "deptformation", "sexe", "niveau",
           "alimentation", "alternant", "reussite", "sport")])

# -----

# TABLEAUX CROISÉS
# -----

TCD_fan      = table(Sport = d$sport, Fan      = d$fan)
TCD_deptformation= table(Sport = d$sport, Dept      = d$deptformation)
TCD_reussite   = table(Sport = d$sport, Reussite   = d$reussite)
TCD_alimentation = table(Sport = d$sport, Alimentation = d$alimentation)
TCD_sexe      = table(Sport = d$sport, Sexe      = d$sexe)
TCD_alternant  = table(Sport = d$sport, Alternant  = d$alternant)
TCD_niveau    = table(Sport = d$sport, Niveau    = d$niveau)


TCD_fan
TCD_deptformation
TCD_reussite
TCD_alimentation
TCD_sexe
TCD_alternant
TCD_niveau
# -----

# TESTS KHI-DEUX
# -----

khideux_fan      = chisq.test(TCD_fan,      correct = FALSE)
khideux_deptformation= chisq.test(TCD_deptformation, correct = FALSE)
khideux_reussite   = chisq.test(TCD_reussite,   correct = FALSE)
khideux_alimentation = chisq.test(TCD_alimentation, correct = FALSE)
khideux_sexe      = chisq.test(TCD_sexe,      correct = FALSE)
khideux_alternant  = chisq.test(TCD_alternant,  correct = FALSE)
khideux_niveau    = chisq.test(TCD_niveau,    correct = FALSE)


khideux_fan
khideux_deptformation
khideux_reussite
khideux_alimentation
khideux_sexe
khideux_alternant
khideux_niveau
# -----

# V DE CRAMER
# -----

n = nrow(d)

```

```

p = nrow(TCD_fan)      ; q = ncol(TCD_fan)      ; m = min(p-1, q-1)
V_fan = sqrt(khideux_fan$statistic / (n*m))
V_fan

p = nrow(TCD_deptformation); q = ncol(TCD_deptformation); m = min(p-1, q-1)
V_deptformation = sqrt(khideux_deptformation$statistic / (n*m))
V_deptformation

p = nrow(TCD_reussite)  ; q = ncol(TCD_reussite)  ; m = min(p-1, q-1)
V_reussite = sqrt(khideux_reussite$statistic / (n*m))
V_reussite

p = nrow(TCD_alimentation) ; q = ncol(TCD_alimentation) ; m = min(p-1, q-1)
V_alimentation = sqrt(khideux_alimentation$statistic / (n*m))
V_alimentation

p = nrow(TCD_sexe)      ; q = ncol(TCD_sexe)      ; m = min(p-1, q-1)
V_sexe = sqrt(khideux_sexe$statistic / (n*m))
V_sexe

p = nrow(TCD_alternant)  ; q = ncol(TCD_alternant)  ; m = min(p-1, q-1)
V_alternant = sqrt(khideux_alternant$statistic / (n*m))
V_alternant

p = nrow(TCD_niveau)     ; q = ncol(TCD_niveau)     ; m = min(p-1, q-1)
V_niveau = sqrt(khideux_niveau$statistic / (n*m))
V_niveau

# --- Tableau récapitulatif ---
recap = data.frame(
  Variable = c("fan", "deptformation", "reussite", "alimentation",
               "sexe", "alternant", "niveau"),
  p_valeur = round(c(khideux_fan$p.value, khideux_deptformation$p.value,
                    khideux_reussite$p.value, khideux_alimentation$p.value,
                    khideux_sexe$p.value, khideux_alternant$p.value,
                    khideux_niveau$p.value), 5),
  V_Cramer = round(c(V_fan, V_deptformation, V_reussite, V_alimentation,
                    V_sexe, V_alternant, V_niveau), 4)
)
recap = recap[order(-recap$V_Cramer), ]
print(recap, row.names = FALSE)

```